方案规划 · 空间科学智能就绪数据集质量评价智能体

> 系统版本 0.8.0 ｜ 规则版本 0.8.0 ｜ 对应交付物 DEL-1 ｜ 依据：需求说明书、评分标准 v1.1（含附件一档位标签）、交付材料清单 v1.1

1. 技术路线

核心判断：空间科学数据没有内禀真值，判据只能来自数据之外——标签自身的声明与物理关系、来源事件目录的约定、同一基础数据的其他质量版本。 据此采用三层确定性判据，由强到弱：

1. **声明与物理一致性**（单数据集）：标签结构、文件配对、数值合法性；采样率 × 时长 = 点数、声明尺寸 = 图像尺寸、起止时刻 = 观测时刻； 活动区中心位于日面内、目标框面积与像素数相符；事件类型与来源目录一致；事件身份标识与同批格式一致。 CME 动能 ≈ ½·质量·速度² 等数值关系也会计算，但属附件一的非计分轨，只作为待复核提示。 **同一事件跨样本一致**（借鉴发榜方参考代码）：LASCO C2 的三帧以同一图像时刻成组、相邻帧标注应与中心帧一致；AIA 同一 HEK 事件出现在约 9 张图像中，类别与时刻应一致——取多数值为参考，与之不同的样本判类别错标或时段抖动（C05 / B05，只在没有同源版本时运行）。
2. **同源质量版本对照**（多数据集）：同一基础数据的多个版本逐样本、逐标注元素比较，判出缺失、错标、漏标、虚标、偏移及其程度。
3. **统计离群**：只落「待判定」，不直接判缺陷。

两条底线：

- **结论可复算**：计量、判定、计分与排序全部由确定性程序按规格公式完成；默认不调用模型（模型服务消耗 0），同一输入重跑逐字节一致。
- **模型只做规则做不了的事**：`--use-llm` 时两个子代理分别「读说明文档、抽取可核对的声明」与「改写整改建议的表述」，都不下结论、不算分（第 3.1 节）。
- **只报能证实的**：附件一的「非计分轨」（需外部基准方可判定）一律弃报为「待判定」并写明需补充的基准材料； 附件一污染项目之外的现象（如图像像素被改动）只列待复核，不判缺陷。

2. 数据范围

数据类型	数据集类型	公开集数据	样本数	标注元素
图像	事件标注型（HEK 事件，外接多边形或单一时刻）	SDO/AIA、SDO/HMI 活动区；SOHO/LASCO C2 日冕物质抛射	3150 / 3017 / 10790（每版本）	事件：类型、多边形、起止时刻、物理参数
图像	矩形框标注型	DMSP SSUSI 极光	286	矩形框：类别 PCA / TPA / unclear
图像	多边形分割型	气辉 EPB 等离子体泡	1350	多边形掩膜
时序	事件区间标注型	地磁 ULF 1 Hz 时序	6120	事件区间：Pi2 / Pc 类型

公开集 6 类 × 5 档（clean、P1～P4），共 30 个数据包、123,565 个样本；档位与污染项目见评分标准附件一。 已验证范围即上述四种数据集类型；其他类型通过规格扩展（第 5 节），未验证前不出具结论。

3. 智能体组成与构建方式

全部构件登记在 `agent/`（manifest / tools / skills / rules / memory / plugins），由 `tools/gen_agent_registry.py` 从规格与检查器注册表生成，测试保证与实现同步。

3.1 三类载体划分与依据

载体	数量	承载什么	划分依据
工具	14 个检查器 + 4 个基础工具	对数据集执行确定性动作：45 项检查（43 项已实现）、数据加载、汇总评分、交付物输出	有执行体、有副作用的归工具；每个检查编号恰好归属一个工具
技能	16 项	判定知识：缺陷代码与计分轨、各标注族约定、物理关系与容差、版本对照判据、跨样本分组、文档声明比对口径、子代理提示词、汇总评分规则	只是知识、没有执行体；全部写在规格 YAML 中，规则版本即技能版本
规则	12 条	行为约束：何时转待判定、什么结论不得输出、失败如何重试、何时终止	约束「不许做什么 / 必须怎么做」，不承载判定知识

另有记忆 2 类（单次运行内，不跨运行持久化）、插件 3 个（检查器注册、标注族定义、模型客户端——默认关闭）、子代理 2 个（默认关闭）。

子代理与划分依据：只把规则做不了、且不影响结论可复算的两件事交给模型，其余全部是确定性程序。

子代理	职责	输入 / 输出契约	委派条件	矛盾仲裁
doc_claim_extractor	读说明文档，抽取样本数、类别、时段、尺寸、模态等可核对的声明	文档正文 → `{claims: [{field, value, quote}]}`，quote 为文档原文	`--use-llm` 且数据集有说明文档（D04）	同一文档调用 2 次只采用一致的声明；摘录在文档中找不到即丢弃；比对与判定由 D04 程序完成，模型不出结论
remediation_writer	把评分卡主要缺陷的整改建议改写得更具体	检查名称、缺陷类型、数量、示例与通用建议 → ≤ 80 字整改步骤	`--use-llm`，全部结论确定之后	不参与判定与计分；失败则保留规格中的通用建议

拆分的收益与代价：收益是能核对自由文本说明文档（需求说明书点名的「说明文档声称覆盖的类别或时段在样本中缺失」）、整改建议更可执行；代价是模型服务消耗（效率分中权重最高的一项，按名次计分）与输出随机性——因此默认关闭，并以「原文摘录校验 + 多次一致」把随机性挡在结论之外。

3.2 编排范式与编排层

- **范式**：`pipeline`（流水线），无模型驱动环节，模型工具白名单为空（子代理只收发文本，不调用工具）。
- **主循环**：发现数据集 → 按质量版本组预分组 → 组内逐数据集执行单数据集检查（依赖拓扑序）→ 组内版本对照 → 降级共有与参考版本问题 → 不可重推项弃报 → 生成报告与评分 → 全局排序与交付物输出。
- **决策点**（manifest 中 DP1～DP6）：标注族识别、检查适用性、前置依赖、同源版本分组与参考版本、缺陷代码与弃报、汇总与排序；每个决策点写明触发条件、输入输出与失败兜底。
- **并发**：按质量版本组多进程并行，进程数 = min(组数, 容器可用 CPU 数)；组间无共享状态，并行与串行结果逐字节一致。
- **状态与上下文**：每个数据集一个上下文对象（已解析标签、逐检查结论、文件指纹），组内比较结果只在本组进程内可见。

3.3 工具集

工具	负责的检查编号	失败模式
标注结构检查器	S01～S06	异常重试 1 次，仍失败该单元落待判定
文件配对检查器	P01～P04	同上（P04：数据集带文件清单时核对清单与实际文件）
标注数值合法性检查器	V01～V03	同上
类别检查器	C01、C02、M01	同上
事件身份标识检查器	M03	同上
边界检查器	B01、B02	同上
物理一致性检查器	V04、B03、B04、C04	同上
跨样本一致性检查器	C05、B05	只在没有同源版本时运行；同一事件出现不足 3 次或无多数取值时不判
数值完好检查器	N01～N03	非 CSV / 非 PNG 落待判定（无读取器）
文档一致性检查器	D01～D03	声明字段缺失落待判定
重复样本检查器	R01	同上
覆盖与分布检查器	G01、U01	无同源版本时 G01 不适用
质量版本对照工具	X01～X08	版本不足或无有效参考时差异落待判定

工具选择逻辑：按标注族（DP1）与用途（DP2）确定适用检查，按 `depends_on` 拓扑排序执行；版本对照工具在全部单数据集检查完成后按组调用。 每个工具的版本、入口、输入输出 schema、超时、重试上限见 `agent/tools.yaml`。

3.4 规则集（摘要）

规则	类型	约束
R01 触及受限边界转待判定	must_flag_pending	前置检查未通过、标注族识别不出、所需字段或材料缺失 → 待判定并写明缺什么
R02 证据位置无法确定不得输出	forbidden_output	无可回查位置的缺陷结论改落待判定
R03 工具失败按上限重试	must_retry	重试 1 次，仍失败落待判定，不改判不适用
R04 未实现检查保留在分母	must_flag_pending	C03、M02 落待判定并写明所缺材料
R05 不可重推项弃报	forbidden_output	非计分轨缺陷不输出不通过
R06 证据不足的维度不计分	forbidden_output	不按 0 分或满分计入综合分与排序
R07～R11	must_stop / quota / forbidden_output	覆盖率不变量、参考版本共有问题降级、排序不并列、运行配额、模型配置缺失即停
R12 模型输出不得直接成为结论	forbidden_output	摘录不在原文即丢弃；多次抽取不一致落待判定；模型输出不进入计量、计分与排序

3.5 记忆层、插件、运行时与护栏

- **记忆**：数据集上下文与版本组上下文，均为单次运行内的进程内存；不读取任何历史记忆，跨运行持久化不存在，重复运行逐字节一致。 记忆不是结论来源，每条结论都回查到原始文件。

- **插件**：检查器注册（新增检查即生效）、标注族定义（新数据类型声明即复用通用检查）、模型客户端（默认关闭，供两个子代理使用，逐次计量消耗）。全部随镜像交付，不从外部加载。
- **运行时**：python:3.11.9-slim-bookworm + PyYAML 6.0.2；主进程 + 每组一个工作进程；Docker `--network none`，输入只读挂载。
- **护栏**：只写 `/output`；不访问网络；并行进程数 ⩽ 可用 CPU 数；启动与镜像构建时校验规格与实现逐条对应，不一致拒绝运行； 每个检查的开始、结束、重试、失败、降级写入运行日志；MANIFEST 记录全部输出文件的 SHA-256。

3.6 确定性边界

环节	是否允许模型介入	本系统
数据读取、解析、校验	不允许	确定性程序
数值计量（比例、偏移、统计量）	不允许	确定性程序
适用性判定	允许，须输出理由	确定性程序（DP2），不适用写明原因
缺陷判定与分类	允许，须给出证据位置	确定性程序；子代理只抽取文档声明（附原文摘录作证据位置），判定由 D04 程序比对
严重程度判断	允许，须引用规范度量	确定性程序（规格 severity_axes）
维度得分与综合排序	不允许	确定性程序（规格 scoring）

3.7 检查项选择、失败恢复、运行记录与人工介入

- **选择逻辑**：适用 = 用途要求且标注族在适用列表内；不适用 = 整项写明原因；待判定 = 触及受限边界（规范 B.2 逐检查边界表）。
- **失败恢复**：检查器异常 → 重试 1 次 → 仍失败则该单元落待判定，运行日志记「重试」「检查失败」「降级」三个事件，未完成事项说明第七节列出。
- **运行记录**：`run.log.jsonl` 一行一事件：时间戳（UTC）、运行编号、数据集、事件类型、检查编号、实际完成 / 失败原因、耗时、资源峰值、模型消耗（默认 0；启用子代理时按检查记录 token 数）、重试次数。
- **人工介入点**：全部「待判定」进入待复核事项，主要是不可重推项（需外部基准）、图像被改动、使用权限文件缺失、来源固有问题； 频次见各数据集评分卡的 reviewAndSupplement。判定过程本身不需要人工。

3.8 结论回查示例

见第 7.1 节（取自公开集实测的一条真实结论，从问题清单逐环回查到原始标签文件）。

4. 质量评价方法

评价规范全文见《数据集质量评价规范（固定版）》，由规格 YAML 自动生成，与实现逐条一致。要点：

1. **缺陷代码**：与附件一污染项目一一对齐（L0-01、L0-03、L2-G、L2-P、L2-T、L2-F、L3-06、L3-07、L3-MIS 为计分轨； L2-A、L2-B、L2-C、L2-M（CME）、L1-TS 为不可重推，一律弃报）；E- 开头为需求说明书必检、附件一未单列的补充类型。
2. **四类状态**：通过 / 不通过 / 待判定 / 不适用全量输出；未实现的适用检查落待判定，不从分母移除。

3. **程度计量**：每条结论带程度（度量名、数值、单位、容差）；偏移类按同一形态内两轴归一后 1:1 的严重度（图像：位置偏移、面积比；无框：时间偏移、相对偏差；时序：时间偏移、采样点变化）。
4. **汇总**：12 项缺陷比例 → 6 个维度分 → 综合分；证据不足的维度不计分；关键缺陷单独列示、不可被抵消。
5. **排序**：全部受评数据集全局排序，不并列，写明主要差异来源。
6. **质量预测**：估计缺陷覆盖率并给出预测档位（同组版本数与档位数相同时按组内名次对应）。

4.1 公开集验证（对照附件一档位标签）

指标	结果
组内排序与档位一致	6 组 30 个包全部一致（clean → P1 → P2 → P3 → P4）
预测档位正确	30 / 30（同组版本数与档位数相同，按组内名次对应）
clean 包上的「不通过」结论	0
缺陷代码不在该包污染项目内的计分轨结论	3 条（全部为 AIA / HMI 的 P1 判覆盖不足，占全部计分轨结论的万分之一量级）
附件一特别提醒的误报点	AIA / HMI 的 P1 报漏标虚标：0；CME 报漏标虚标或边界偏差：0
不可重推项「不通过」结论	0（全部弃报为待判定，写明需补充的基准材料）
效率	全量约 12 分钟（6 进程；0.7.0 实测 12 分 21 秒，0.8.0 在服务器高负载时 15 分 41 秒）；镜像 133 MB；单进程峰值内存 1.5 GB；执行失败 0；模型服务消耗 0
输出规模	问题清单 168,326 条（不通过 96,342、待判定 70,693、通过 841、不适用 450 条汇总记录）；运行日志 2,360 个事件

各包的估计覆盖率与按缺陷代码的样本数见公开集实测材料 `tier_eval.txt`。

4.2 无同源版本时（独立数据集）

隐藏集「含质量变体与独立数据集」。对独立数据集，版本对照不适用，主要靠单数据集判据。借鉴发榜方参考代码（OPC-code）后新增的跨样本一致检查， 在公开集上逐个数据集单独运行的实测（至少有一条计分轨「不通过」结论的样本占比；clean 包误报均为 0）：

数据集	P1	P2	P3	P4
CME（原有判据 → 加跨样本一致）	0.1% → 2.4%	1.2% → 6.9%	4.8% → 10.9%	10.3% → 14.9%
AIA（原有判据 → 加跨样本一致）	2.3% → 2.3%	10.0% → 10.3%	23.5% → 24.2%	35.0% → 38.2%

AIA 的类别错标多数已由「事件类型汇总与明细不一致」（S06）在样本层面判出，跨样本一致检查主要补充到具体事件；CME 帧组一致性提升最明显。 同时修正了单数据集模式的一处误报来源：源事件目录中完全相同的重复事件（各档数量不随污染增加）改列待复核。

5. 任务适配方式

- **新数据类型**：在规格 `profiles` 中声明数据类型、数据集类型、识别字段、标注元素路径、类别键、几何键、时间键与身份键； 通用检查、版本对照、程度计量与排序自动生效。`tools/gen_profile.py` 读样本自动生成草稿并逐项实测命中率（公开集实测：EPB、DMSP、ULF 的草稿与人工编写的配置完全一致；AIA、HMI、CME 的草稿各自是人工配置 hek_image 的子集——人工配置合并了三类的字段），可选用模型补全中文说明，人工审核后写入规格。

- **新检查**：规格中声明编号（类别字母 + 两位序号）、缺陷代码、适用范围与受限边界，并实现同编号检查器；规范文档与构件登记自动重新生成。
- **新用途**：在 `purposes` 中声明，并在检查上标注适用用途。
- **阈值调整**：全部阈值、容差、权重都在规格中，修改后规则版本与规格指纹随之变化，报告可追溯所用版本。

6. 实施计划

阶段	时间	内容
已完成	至 2026-10-19	原型、评价规范、公开集全量实测、按 v1.1 材料完成格式与口径对齐（见第 7 节）
中期反馈	中期答疑	提交评价规范草案，按反馈调整；确认评测细则中的容差与 B 项阈值
冻结	隐藏测试前	冻结规则版本，镜像与规范一并提交，不再改动阈值
答辩	决赛	现场运行与问答，演示视频 ⩽ 5 分钟

7. 已完成内容

- 可运行原型：Docker 镜像（离线 load + run）、源码、45 项检查（43 项已实现）、按交付材料清单 §三 的输出结构；两个可选模型子代理。
- 开发辅助工具：`tools/gen_profile.py`（为新数据类型生成标注族草稿并实测校验，可用 DeepSeek 等模型补全）、`tools/llm_review.py`（让模型对照评分要求审阅交付文档）——只在开发时使用，不进入镜像的评测流程。
- 评价规范：YAML 唯一权威版本 + 自动生成的文档，含类型对应关系总表、逐检查边界表、展开表、不适用性声明表、范围与边界声明总表、一致性核对。
- 智能体构件登记：agent/ 六个文件，与实现自动同步。
- 公开集实测材料：30 份评分卡、全局排序表、问题清单、证据索引、运行日志、未完成事项说明、档位标签对照结果。

7.1 结论回查示例

取自公开集实测（运行编号 `run-63be27edc261216a`，系统与规则版本 0.8.0）的一条真实结论，按评测端抽查链条逐环回查：

环节	内容
① 结论记录（`06_问题清单/findings.jsonl`）	`findingId` = `B03-HMI_AR_sample_ykt33mm8o2-000008`；状态「不通过」；缺陷代码 L2-G 边界与位置偏差；说明「目标中心落在日面以外（位置偏移）」；程度：目标中心到日心距离 / 太阳半径 = 1.1636 R⊙，容差 1.05
② 检查编号 → 工具（`agent/tools.yaml`）	B03 属工具 `sqa.checks.physics`（物理一致性检查器），版本 0.8.0，入口 `/app/src/sqa/checks/physics.py`，确定性，重试上限 1
③ 检查编号 → 技能（`agent/skills.yaml`）	`solar_physics`：日面边缘余量 1.05、像素尺度（HMI 0.504″/px，按 4096 / 实际宽度缩放），规格路径 `spec/quality_spec.yaml#physics`
④ 检查编号 → 规则（`agent/rules.yaml`）	R01（缺 rsunObs 时转待判定）、R02（无位置不得输出）、R03（失败按上限重试）

环节	内容
⑤ 运行日志（`08_运行日志/run.log.jsonl`）	2026-10-22T13:19:44.430Z「检查开始」→ 13:19:44.719Z「检查结束 · 实际完成」，耗时 288.5 ms，重试 0，模型消耗 0
⑥ 证据索引（`07_证据索引/evidence_index.csv`）	`EV-B03-HMI_AR_sample_ykt33mm8o2-000008`；定位类型 imageRegion；位置 `HMI_AR_sample_ykt33mm8o2/label/4HUaQXWwiLRL90dajz9H.png.json#hek_event_annotation.matched_events[5]@bbox=0.0,2816.6,68.2,2963.8`；文件校验值 `ffd51558…cdf5107`
⑦ 原始文件	打开上述标签文件第 6 个事件：类型 AR，多边形顶点 x 坐标 0.0～68.2（贴近图像左边缘）；`science_annotation.rsunObs` = 951.37″ → 日面半径 1887.6 px，目标中心距图像中心 2196.4 px = 1.16 个日面半径，超出容差。文件 SHA-256 与证据索引一致

第三方可按 ⑦ 的数值与规格中的公式（`spec/quality_spec.yaml#physics`）独立复算出同一结论。现场可用 `tools/show_evidence.py` 输入结论编号，一键生成上述各环与原图红框的抽查页。

8. 后续改进安排

- 收到《OPC 评测细则》后：按公开容差调整位置匹配与程度计量口径；核对 B 项检出率定义。
- 收到档位与高 / 中 / 低等级的对应关系后：把暂定等级替换为正式等级。
- 收到划分清单后：实现数据划分重复与泄漏检查（E-SPL）。
- 独立数据集（无同源版本）：已借鉴发榜方参考代码加入跨样本一致检查（4.2 节），下一步接入外部事件目录（HEK、CDAW CME 目录、台站事件表），把漏标、虚标与不可重推项推进到确定性判定。